

คำอธิบาย Lab1.2

```
▼ Import tools

[ ] from google.colab import files
    uploaded = files.upload()

Choose Files No file chosen Upload widget is only available when the cell has been executed in the current browser session. Please rerun this cell to enable.
Saving Credit-Card-Defaulter-Prediction.csv to Credit-Card-Defaulter-Prediction.csv

▶ import numpy as np
import pandas as pd
import seaborn as sns
from sklearn import preprocessing
from sklearn.feature_selection import chi2
```

- Import library ที่จะใช้ในการเขียนโปรแกรม

```
▼ 1. Data Exploration

Read the Data_example.csv files

► Columns Information

[ ] ### START CODE HERE ###
    df = pd.read_csv('/content/Credit-Card-Defaulter-Prediction.csv', encoding = "ISO-8859-1")
    df
    ### END CODE HERE ###
```

- Import csv file ที่จะใช้ในการเขียนโปรแกรม
- Print df ออกมา

```
Remove column ID.

► Hints

[ ] ### START CODE HERE ###
    df.drop('ID', axis='columns', inplace=True)
    df

    ### END CODE HERE ###
```

- ลบ column 'ID'

```
df.info()  
df.describe()  
# df.median()
```

- แสดงข้อมูล datatype ของแต่ละ column ใน df
- แสดงค่าที่คำนวณออกมาได้จาก column ทั้งหมดของ df เช่น count, mean, std, min, 25% 50%, 75%, max

```
df.columns
```

- แสดง index ชื่อ column ทั้งหมด

```
### START CODE HERE ###  
  
df = df.fillna(df.median())  
df  
  
### END CODE HERE ###
```

- Fill ข้อมูลที่เป็น N/A ด้วย median เนื่องจากค่า max ดูโดดจากข้อมูลอื่นเกินไปเกินไปจึงอาจจะทำให้ค่า mean เปลี่ยนไปได้

```
df.info()
```

- แสดงข้อมูล datatype ของแต่ละ column ใน df

```

▶ ### START CODE HERE ###

correlation_matrix = df.corr()
correlation_matrix

### END CODE HERE ###

```

- คำนวณค่า correlation ของข้อมูลทั้งหมดและใส่ไว้ในตัวแปร correlation_matrix
- Print correlation_matrix

```

[ ] sns.heatmap(correlation_matrix)

```

- สร้าง heatmap จากค่า correlation

```

[ ] ### START CODE HERE ###
lower = np.tril(correlation_matrix,-1)
### END CODE HERE ###

```

▶ Expected output

```

[ ] sns.heatmap(lower)

```

- แสดงค่าเฉพาะ Lower triangle ของ heatmap

```

▶ ### START CODE HERE ###


dfCopy = df.copy()
lower = correlation_matrix.where(np.tril(np.ones(correlation_matrix.shape), k=-1).astype(bool))
to_drop = [column for column in lower.columns if any(lower[column] > 0.6)]
dfCopy.drop(to_drop, axis=1, inplace=True)
dfCopy
### END CODE HERE ###

```

- สร้างตัวแปร dfCopy ขึ้นมาเพื่อคัดลอก df

- ให้ drop column ที่มีค่า correlation มากกว่า 0.6 เพราะข้อมูลมีความเหมือนกันมาก

► Expected output

 dfCopy.describe()

- แสดงค่าที่คำนวณออกมาได้จาก column ทั้งหมดของ dfCopy เช่น count, mean, std, min, 25% 50%, 75%, max

```
### START CODE HERE ###  
  
# non_numeric_columns = df['SEX', 'EDUCATION', 'MARRIAGE','default'].unique()  
  
# non_numeric_columns = np.unique(df[['SEX', 'EDUCATION', 'MARRIAGE']].values)  
non_numeric_columns = df.select_dtypes(exclude=['number'])  
non_numeric_columns  
# df[non_numeric_columns.columns].unique()  
  
### END CODE HERE ###
```

- สร้างตัวแปร non_numeric_columns ขึ้นมาเพื่อสร้างตารางใหม่ที่มีเฉพาะ columns ที่ข้อมูลที่ไม่ใช่ตัวเลข(ตัวอักษร)

```
### START CODE HERE ###  
  
label_encode = preprocessing.LabelEncoder()  
df_encode = non_numeric_columns.apply(label_encode.fit_transform)  
  
df_encode = df_encode.astype('int64')  
# df_encode.info()  
dfCopy.update(df_encode.astype('int64'))  
# dfCopy  
### END CODE HERE ###
```

- แปลงข้อมูลที่เป็นตัวอักษรให้กลายเป็นตัวเลข

```

▶ ### START CODE HERE ###
output = df_encode['default ' ]
variable = df_encode[['SEX', 'EDUCATION', 'MARRIAGE']]

chi2_stat, p_values = chi2(variable,output)

chi2_table = pd.DataFrame({
    "Feature": variable.columns,
    "Chi2 Statistic": chi2_stat,
    "P-Value": p_values
})
### END CODE HERE ###
chi2_table

```

- คำนวณค่า chi-Square และ P-value ของ column 'SEX', 'EDUCATION', 'MARRIAGE' ว่าส่งผลต่อ 'default ' มากแค่ไหน

```

[ ] ### START CODE HERE ###
to_drop = chi2_table[chi2_table['P-Value'] > 0.05]
print("to_drop :",to_drop.Feature)
dfCopy.drop(to_drop.Feature, axis=1, inplace=True)
### END CODE HERE ###

```

- Drop column ที่มีค่า P-value มากกว่า 0.05 คือ 'MARRIAGE' เนื่องจากไม่มีผลต่อ 'default '

▶ dfCopy

- แสดงตารางข้อมูลล่าสุดที่ทำการ clean เรียบร้อยแล้ว